Střední průmyslová škola elektrotechnická
a Vyšší odborná škola
Pardubice, Karla IV. 13

TEORIE OBVODŮ
XI

(DIGITALIZACE ZVUKOVÉHO SIGNÁLU)

Ing. Jiří Nobilis

Pardubice **2006**

Toto skriptum věnuji všem zájemcům o moderní způsob přenosu a uchovávání zvukové informace. Zpracovávané téma je velmi rozsáhlé, takže skriptum nemůže zachytit všechny detaily a podrobnosti, zvláště tehdy, když dochází k velmi prudkému vývoji různých kompresních algoritmů. Snahou bylo dát zájemcům do ruky spisek, který vysvětluje fyzikální podstatu, principy a cesty dalšího možného vývoje komprimačních technik. Předpokladem pro studium tohoto skripta je zvládnutí předchozích dílů skript „Teorie obvodů“ (zvláště skripta **TO X**) a základů akustiky. Po zvládnutí základů, uvedených v tomto skriptu, předpokládám, že čtenář bude studovat další prameny, které mu v tomto oboru rozšíří obzory.

Děkuji Ing. Vlastislavu Kazdovi za cenné připomínky k textu a jeho uspořádání.

Autor

Ing. Jiří Nobilis, 2006

Tato publikace neprošla redakční ani jazykovou úpravou.

Obsah **3**

11 Úvod **4**

11.1 Fyziologické předpoklady komprimace digitalizovaného akustického signálu **5**
11.1.1 Vnímání zvuku 5
11.1.2 Frekvenční charakteristika lidského ucha 7
11.1.3 Maskování 8
11.1.4 Kritická šířka frekvenčního (sub)pásma 10

11.2 Vzorkování, kvantizace a digitalizace akustického signálu **11**

11.3 Psychoakustický model lidského sluchu **12**

11.4 Kompresní metody **14**

11.4.1 Kompresní standard MPEG-1 14

11.4.2 Kompresní standard MPEG-2 17

11.4.3 Kompresní standard MPEG-2 AAC 17

11.4.4 Kompresní standard MPEG-4 18

11.4.5 Systém ATRAC 19

11.4.6 Systém SDDS 20

11.4.7 Systém Dolby AC-3/Dolby Digital/Dolby SR-D 20

11.4.8 Technika SBR 21

11.5 Přehled standardů používaných pro kompresi zvukové informace **21**

11.6 Závěr **21**

11.7 Použitá a doporučená literatura **22**

11 Ú v o d

V době překotně se rozvíjející techniky počítačů nezůstal stát stranou ani obor, který donedávna ovládala výhradně analogová technika. Po prvních nesmělých krůčcích, které techniku záznamu akustického signálu přivedly ke kompaktnímu disku (CD), dochází k překotnému rozvoji nových kompresních metod, které umožňují zvýšit hustotu zaznamenávané informace a které jsou současně předpokladem pro zavedení digitálního vysílání rozhlasových pořadů. Tyto nové kompresní metody do důsledků využívají poznatků z fyziologie slyšení.

Jaký je rozdíl mezi analogovým a digitálním zpracováním akustické informace?

Analogové zpracování využívá akustického signálu získaného z mikrofonu k přímému přenosu nebo záznamu. Příkladem může být stávající rozhlasové vysílání, které probíhá pomocí analogových modulací AM nebo FM, eventuálně analogový záznam zvuku (magnetický, mechanický, optický). Přitom přenos probíhá v reálném čase, je souvislý a trvalý. Rušení, které do analogového signálu pronikne, nelze jednoduchými prostředky odstranit.

Při **digitálním zpracování** lze redukovat objem přenášených (nebo zaznamenávaných) dat s ohledem na fyziologické vlastnosti lidského ucha. Digitální signál je možné pro přenos seskupovat do paketů, případné rušení je méně významné než u analogového signálu, protože na přijímací straně je možné číselné hodnoty obnovit. Digitální signál je navíc možné při přenosu zabezpečit vhodným zabezpečovacím kódem (FEC = forward error correction).

Digitalizace akustického signálu potom probíhá následovně:

vzorkování	**kvantování**	**kódování**
zjištění hodnoty signálu v přesně definovaném čase, možnost určení polohy vzorku číslem	převedení do oboru nespojitých číselných hodnot; přesnost převodu závisí na počtu kvantizačních úrovní	vyjádření čísla binární formou

Zpracování dat probíhá v několika krocích:

transformace do frekvenční oblasti	**redukce dat**	**zabezpečení dat**
nahrazení hodnot akustického signálu frekvenčními koeficienty	vyloučení redundantních údajů - redukce velikosti koeficientů (amplitud vyšších harmonických složek)	vytvoření údajů pro obnovení dat porušených při přenosu

11.1 Fyziologické předpoklady komprimace digitalizovaného akustického signálu

11.1.1 Vnímání zvuku

Pro člověka je sluch druhým nejdůležitějším smyslem hned po zraku. Kromě vnímání zvuků z okolí umožňuje také vzájemnou komunikaci mezi lidmi. Proto také elektroakustika zaujímá významné místo mezi technickými komunikačními prostředky. Existují však výrazné rozdíly mezi objektivními fyzikálními veličinami a subjektivním vnímáním zvuku.

Jako akustické receptory slouží člověku značně složité orgány, uši. Ušní boltce upravují směrovou charakteristiku vnímání zvukových podnětů. Odtud zvuk přichází do vnějšího a potom do vnitřního zvukovodu. Dále je akustický vzruch přenášen přes bubínek, kovadlinku a třmínek ve středním uchu do tzv. "hlemýždě", v němž je chvění převáděno na nervové vzruchy, které jsou pomocí sluchového nervu přenášeny do mozku, kde jsou dále zpracovávány. Protože má člověk dvojici receptorů, může rozlišovat směr, odkud akustický vzruch přichází. Je tedy možné hovořit o lidské schopnosti prostorového vnímání zvukových podnětů.

Z fyzikálního hlediska není zvuk omezen na chvění vzduchu, vnímané sluchem, ale je obecně definován jako chvění, které se šíří vzduchem (případně jiným prostředím).

Rychlost šíření zvuku (akustického signálu, přenášeného vlněním) závisí na prostředí, v němž se zvuk šíří. Obecně platí

$$c_0 = \sqrt{\frac{K}{\rho}},$$

kde **K** je modul objemové pružnosti prostředí, jímž se zvuk šíří a ρ je hustota tohoto prostředí.
V případě plynů (vzduch) při adiabatické změně platí

$$K = \kappa \cdot p_{00},$$

kde

$$\kappa = \frac{c_p}{c_V}$$

($\mathbf{p_{00}}$ je aktuální hodnota barometrického tlaku, $\mathbf{c_p}$ měrné teplo při konstantním tlaku p a $\mathbf{c_V}$ měrné teplo při konstantním objemu V.
Vlivem změn parametrů ovzduší tak dochází i ke změně rychlosti šíření zvuku. Nejvýraznější závislost má rychlost šíření zvuku na teplotě:

$$c_0 = \sqrt{\frac{\kappa \cdot p_{00}}{\rho_0} \cdot (1 + \gamma \cdot \vartheta)} = 331{,}8 + 0{,}607 \cdot \vartheta \quad \left[\mathrm{m \cdot s^{-1}; °C}\right].$$

Ve výše uvedeném vztahu uvažujeme hodnoty $\mathbf{p_{00}}$ a ρ_0 při teplotě 0 °C, γ je teplotní součinitel objemové roztažnosti vzduchu.

Při šíření zvuku se uplatňuje **Huyghensův princip** - z bodového zdroje se zvuk šíří v kulových vlnoplochách, přičemž každý bod kterékoliv kulové vlnoplochy můžeme považovat za další bodový zdroj zvuku.

Objektivně může být úroveň zvuku vyjádřena akustickým tlakem nebo intenzitou akustického pole.

Akustický tlak představuje střídavou složku tlaku, jež je superponována na atmosférický tlak. Pro střední a efektivní hodnotu akustického tlaku (udávaného v Pa nebo v barech) platí:

$$p_{av} = \frac{1}{T}\cdot\int_0^T p(t)dt; \quad p_{ef} = \sqrt{\frac{1}{T}\cdot\int_0^T p^2(t)dt}\,.$$

Protože lidský sluch je schopen vnímat zvuky s akustickým tlakem nebo intenzitou v rozsahu mnoha řádů, používá se poměrného logaritmického vyjádření akustického tlaku ve formě **hladin akustického tlaku** v decibelech; jako referenční úroveň byl zvolen akustický tlak $\mathbf{p_0 = 2\cdot10^{-5}\ Pa}$ (práh slyšení - střední hodnota, zjištěná pozorováním a statistickým zpracováním údajů) při frekvenci 1 kHz:

$$L_p = 10\cdot\log\frac{p^2}{p_0^2} = 20\cdot\log\frac{p}{p_0}\,[\mathrm{dB}].$$

Intenzita akustického pole je definována jako akustický výkon, jenž prochází příslušnou plochou

$$I = \frac{P}{S}\,[\mathrm{W\cdot m^{-2}}].$$

Obdobně jako pro akustický tlak se i pro intenzitu akustického pole používá **hladin intenzity akustického pole**; referenční intenzita je $\mathbf{I_0 = 10^{-12}\ W\cdot m^{-2}}$ (odpovídá p_0 při $\rho\cdot c_0$ = 400 $\mathrm{kg\cdot m^{-2}\cdot s^{-1}}$):

$$L_I = 10\cdot\log\frac{I}{I_0}\,[\mathrm{dB}].$$

Pro frekvenci 1 kHz odpovídá hladina intenzity akustického pole v **dB** hlasitosti, jež je udávána ve **fónech (Ph)**.

V některých případech se můžeme setkat i s **hladinami akustického výkonu**, přičemž $\mathbf{P_0 = 10^{-12}\ W}$ (za stejné podmínky, jaká platí pro I_0):

$$L_P = 10\cdot\log\frac{P}{P_0}\,[\mathrm{dB}].$$

Poznámka:

Na akustický tlak reaguje lidské ucho logaritmicky (Weber - Fechnerův zákon pro hlasitost): „**Přírůstek počitku (subjektivního vjemu) je úměrný relativní změně intenzity akustického pole**“.

$$d\gamma = k\cdot\frac{dI}{I} \quad\Rightarrow\quad \Delta\gamma = \int_{\gamma_1}^{\gamma_2} d\gamma = k\cdot\int_{I_1}^{I_2}\frac{dI}{I} = k\cdot\ln\frac{I_2}{I_1}.$$

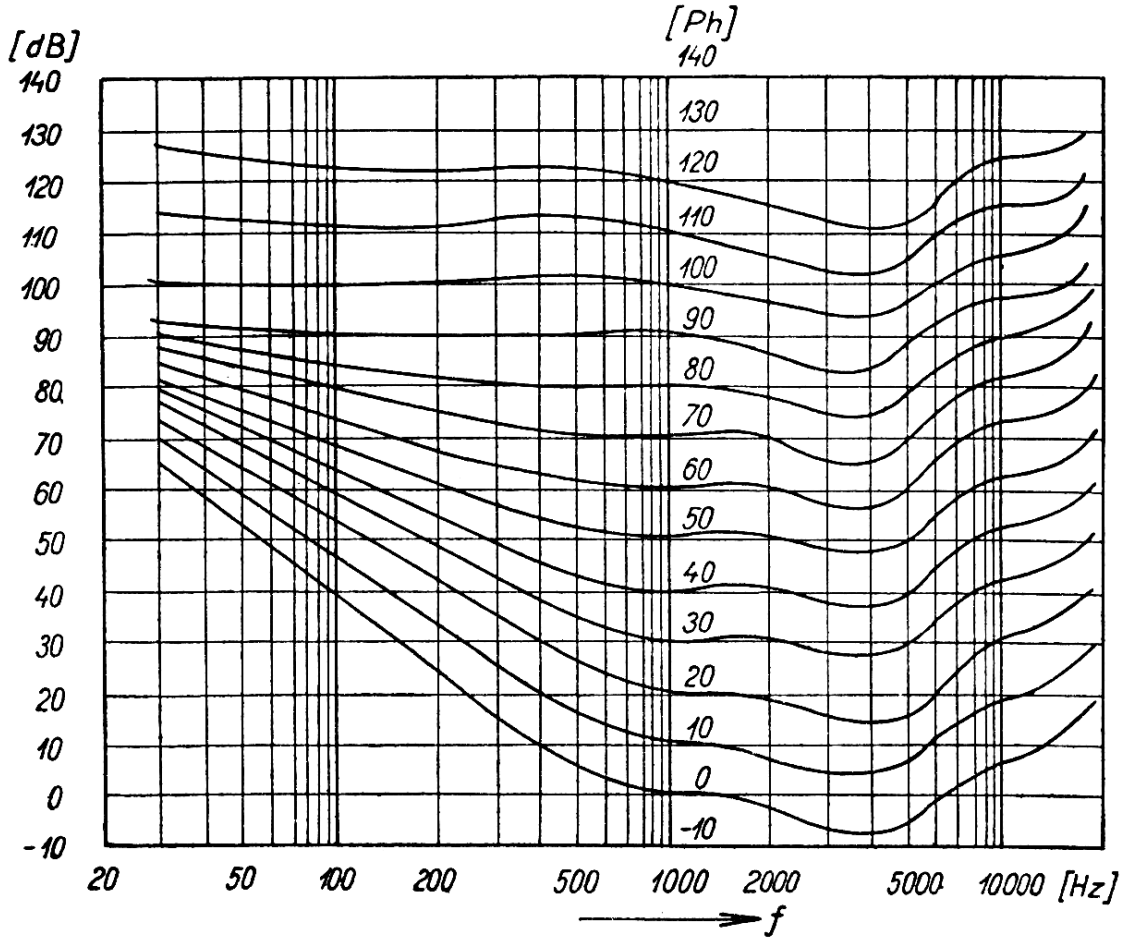
Právě z tohoto důvodu je zavedení hladin akustických veličin velmi účelné. V praxi je výhodnější použití dekadického logaritmu (log) a vyjádření v dB (z přirozeného logaritmu vychází jednotka 1 Neper).

Lidské ucho nevnímá všechny úrovně a všechny frekvence stejně. Například v tichém prostředí může registrovat velmi slabé zvuky, jestliže se však vyskytne zvuk s vysokou intenzitou, ucho se na něj adaptuje a bude rozlišovat zvuky jen v omezeném dynamickém rozsahu. Po skončení silného zvuku nebude ucho původní slabé zvuky vnímat, začne je rozeznávat až po určité době, v níž se opět adaptuje na ticho. Kromě toho se s úrovní akustického signálu mění také vnímání zvuků na

různých frekvencích. Při nižších úrovních a stejném akustickém tlaku vnímá ucho tóny s nízkými a vysokými frekvencemi jako zvuky s nižší hlasitostí. Citlivost na vysoké tóny klesá u osob starších a u osob vystavených působení silného hluku. Pro technické účely se používají generalizované charakteristiky, stanovené pro průměrný lidský sluch (viz dále).

11.1.2 Frekvenční charakteristika lidského ucha

Lidské ucho vnímá akustické vzruchy v rozmezí frekvencí asi 16 Hz až 16 kHz. Generalizované křivky čistých (spektrálních) tónů vnímaných se stejnou hlasitostí jsou zobrazeny v následujícím diagramu. Zvláštní pozornost si zaslouží křivka 0 fónů - práh slyšení. Z ní lze například zjistit, že při frekvenci 100 Hz začne ucho tón vnímat až při akustickém tlaku značně vyšším než při frekvenci 1 kHz. Na základě těchto křivek je v analogových akustických systémech používána tzv. fyziologická regulace hlasitosti, systémy s digitálním zpracováním signálu umožňují odstranění dat, jež charakterizují signály pod touto mezí.



obr. 11.1.2-1

Z grafu na obr. 11.1.2-1 (Fletcher - Munsonovy křivky) lze zjistit hodnoty akustického tlaku nebo intenzity akustického pole v závislosti na frekvenci při konstantních hladinách hlasitosti (při stejném subjektivním vjemu). Hladiny hlasitosti se udávají ve fónech (Ph) a číselně odpovídají hladinám akustického tlaku L_p při frekvenci f = 1 kHz. Nejnižší křivka určuje práh vnímání akustického signálu (úrovni

0 dB odpovídá prahový akustický tlak $p_0 = 2.10^{-5}$ Pa a prahová intenzita akustického pole $I_0 = 1.10^{-12}$ W/m^2).

Poznámka 1:

Z obr. 11.1.2-1 je patrné, že je frekvence na vodorovné ose vynášena logaritmicky. To je též důsledkem fyziologie slyšení. Weber - Fechnerův zákon pro tento případ říká: „**Přírůstek relativní výšky tónu $\Delta\nu$ je úměrný relativní změně frekvence**“.

$$d\nu = k \cdot \frac{df}{f} \quad \Rightarrow \quad \Delta\nu = \int_{\nu_1}^{\nu_2} d\nu = k \cdot \int_{f_1}^{f_2} \frac{df}{f} = k \cdot \ln \frac{f_2}{f_1}.$$

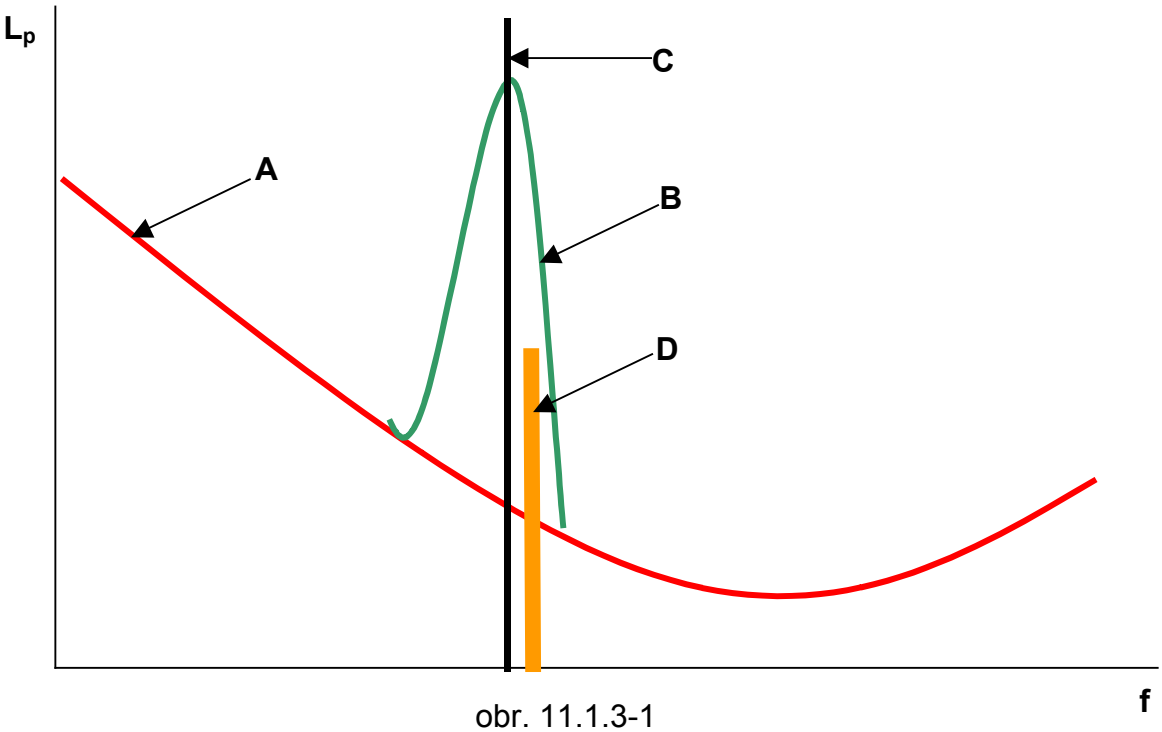
Poznámka 2:

Je obecně známo, že i frekvenční charakteristiky jednobranů nebo dvojbranů v oblasti nízkých (slyšitelných) frekvencí mají frekvenční osu vynášenu v logaritmickém měřítku. Pro snazší výpočty se používá opět dekadický logaritmus - logaritmický rozdíl frekvencí určuje dekádu (násobek 10x nebo podíl 1/10) nebo oktávu (dvojnásobek nebo polovina).

11.1.3 Maskování

Pod pojmem maskování rozumíme tu skutečnost, že ucho přestává vnímat slabší akustický signál při výskytu značně silnějšího signálu s blízkou frekvencí. Rozlišujeme maskování současné a maskování v časové oblasti.

K **současnému maskování** dochází, když se v signálu vyskytne silný tón, který výrazně překračuje práh slyšitelnosti na příslušné frekvenci a má také značně vyšší úroveň než ostatní signály s blízkými frekvencemi. Tuto situaci blíže objasňuje obr. 11.1.3-1.



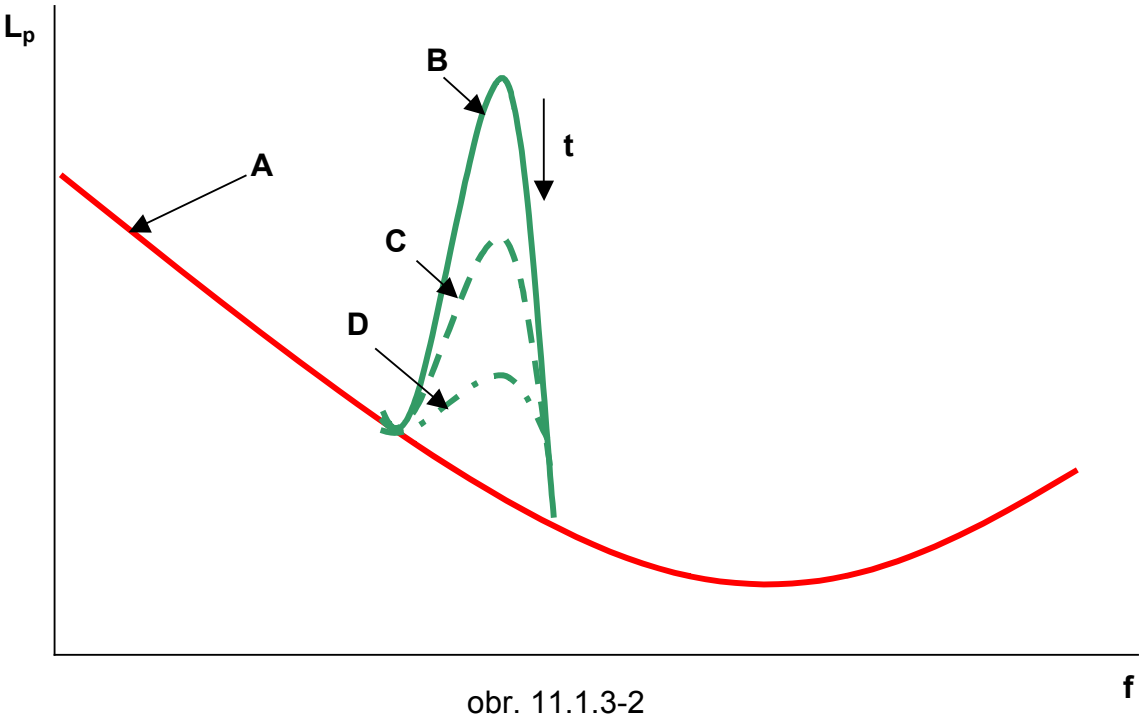
obr. 11.1.3-1

A - normální práh slyšení
B - modifikovaný práh slyšení
C - úzkopásmový akustický signál (dominantní tón)
D - frekvenčně blízký jiný tón s nižší amplitudou (pod modifikovaným prahem slyšení)

Jestliže akustický signál **C** vyvolá „deformaci“ prahové úrovně **B** v uvažované části akustického spektra (akustickém subpásmu), přičemž tato „deformovaná“ křivka překročí úroveň tónu **D**, tón **D** se v subjektivním vjemu akustického signálu neprojeví. Můžeme proto:

a) zmenšit dynamiku signálu (tj. pro kvantování digitálního signálu v daném frekvenčním subpásmu použijeme menší počet bitů);
b) informaci o maskovaném tónu **D** zcela vypustit.

O **maskování v časové oblasti (dynamickém maskování)** hovoříme v souvislosti s adaptabilitou lidského sluchu. Jestliže totiž přestane dominantní tón znít, práh slyšení lidského ucha se k původní hodnotě vrací s určitým časovým zpožděním (asi po dobu 10 ms ucho ukončení tónu vůbec nevnímá, potom dochází k přibližně exponenciálnímu poklesu subjektivního vjemu, který trvá celkem přibližně 200 ms). Po tuto dobu tedy stále ještě probíhá maskování, i když s měnícím se maskovacím prahem (obr. 11.1.3-2).



obr. 11.1.3-2

A - normální práh slyšení (globální práh - viz Fletcher - Munsonovy křivky)
B - modifikovaný práh slyšení těsně po ukončení dominantního tónu v daném akustickém subpásmu (0 až 10 ms)
C - modifikovaný práh slyšení po uplynutí asi 50 ms
D - modifikovaný práh slyšení po uplynutí asi 100 ms
Případy B, C a D představují časově závislé místní maskovací prahy.

Obdobný případ nastane i při nárůstu hlasitosti (náběhu) dominantního tónu, pořadí prahů slyšení pak bude přesně opačné (A, D, C, B).

K podobnému jevu dojde i v případě, že se krátce (max. 5 ms) před maskujícím tónem objeví jiný, frekvenčně blízký a krátký slabší akustický impuls. Tento jev není zatím uspokojivě vysvětlen; zdá se, že ucho „rychleji“ vnímá hlasitější tóny než tóny s menší intenzitou.

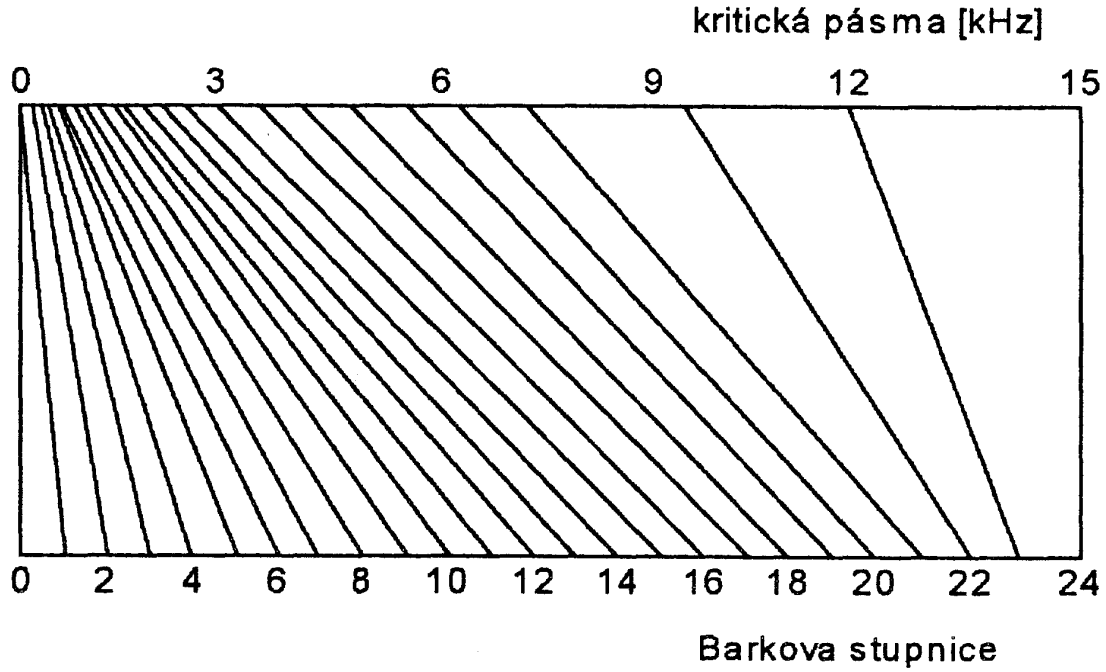
Maskovací jev při digitalizaci umožňuje použít menší kvantizační hloubku, která by bez maskovacího jevu nebyla dostatečná.

11.1.4 Kritická šířka frekvenčního (sub)pásma

Z křivek stejné hlasitosti a z teorie maskování je zřejmé, že prahové hodnoty se pro různé frekvence značně liší. Vyhodnocování jednotlivých frekvencí by bylo velmi náročné. Proto je účelné rozdělit celé frekvenční spektrum na dílčí pásma (subpásma), která na sebe navazují.

Pojmem kritická šířka frekvenčního (sub)pásma rozumíme takovou šířku frekvenčního pásma, která na sluchové ústrojí působí tak, že vyvolává jediný celkový vjem. Tomuto frekvenčnímu pásmu odpovídá 1 Bark (podle drážďanského profesora Georga Heinricha Barkhausena, který mimo jiné zavedl i jednotku hlasitosti 1 Ph).

Celkové slyšitelné frekvenční pásmo tak můžeme rozdělit na 24 sousedících kritických frekvenčních subpásem. Na obr. 11.1.4-1 je znázorněn vztah mezi mezními frekvencemi kritických subpásem a rozdělením pomocí jednotek Bark (Barkova stupnice = frekvenční dělení na kritická pásma v jednotkách Bark).



obr. 11.1.4-1

Frekvenční subpásma, jež jsou uvedena na obr. 11.1.4-1, sahají do frekvence 15 kHz. Šířky kritických frekvenčních subpásem na vyšších frekvencích (nad 10 kHz) jsou neustále předmětem výzkumu.

Pro účely stanovení úrovně maskování je výhodné akustické pásmo rozdělit na větší počet užších dílčích subpásem, (většinou se používá rozdělení na 32 dílčích subpásem, sahajících do 20 kHz), čímž se v užším pásmu zmenší pravděpodobnost,

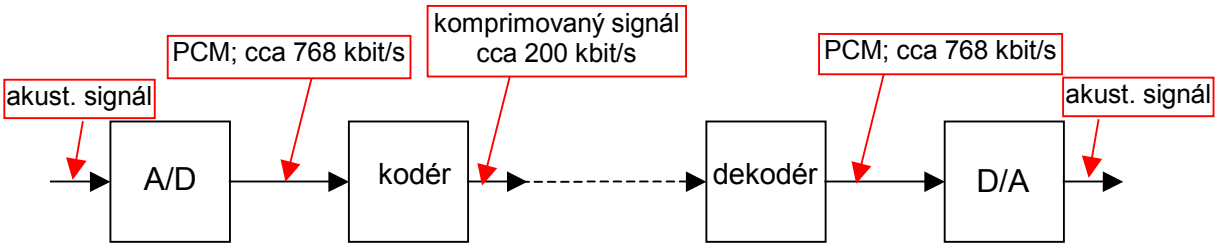
že daný tón nebude maskován. Pokud by k maskování nedošlo, zůstane na obr. 11.1.3-1 základním prahem křivka **A**.

Rozdělení celkového frekvenčního pásma na dílčí frekvenční subpásma využívá prakticky každý kompresní algoritmus.

11.2 Vzorkování, kvantizace a digitalizace akustického signálu

Pro zpracování akustického signálu ve vysoké kvalitě je potřebné provést vzorkování frekvencí 48 kHz při šestnáctibitovém kvantování (připouští se i vzorkovací frekvence 44,1 kHz obvyklá u záznamu na CD nebo frekvence 32 kHz u doprovodného zvuku televize).

Schéma přenosového řetězce, jenž využívá komprimaci akustického signálu, je uvedeno na obr.11.2-1.



obr. 11.2-1

Akustický signál je vzorkován (PAM), posléze kvantizován a převeden na PCM s datovým tokem asi 768 kbit/s. V kodéru dojde ke komprimaci, čímž se datový tok sníží na hodnotu asi 200 kbit/s. Komprimovaný signál je přenášen (nebo zaznamenáván), následně se přivádí do dekodéru a převodníku D/A, za nímž je opět rekonstruovaný akustický signál (který již nikdy nebude zcela odpovídat původnímu, neboť používané komprimační algoritmy jsou většinou ztrátové).

Zvolený stupeň komprese je vždy kompromisem mezi požadovanou kvalitou výsledného signálu a datovým tokem. Při tom je důležité, aby byly přeneseny všechny relevantní informace a zbytečná data byla v nejvyšší míře potlačena.

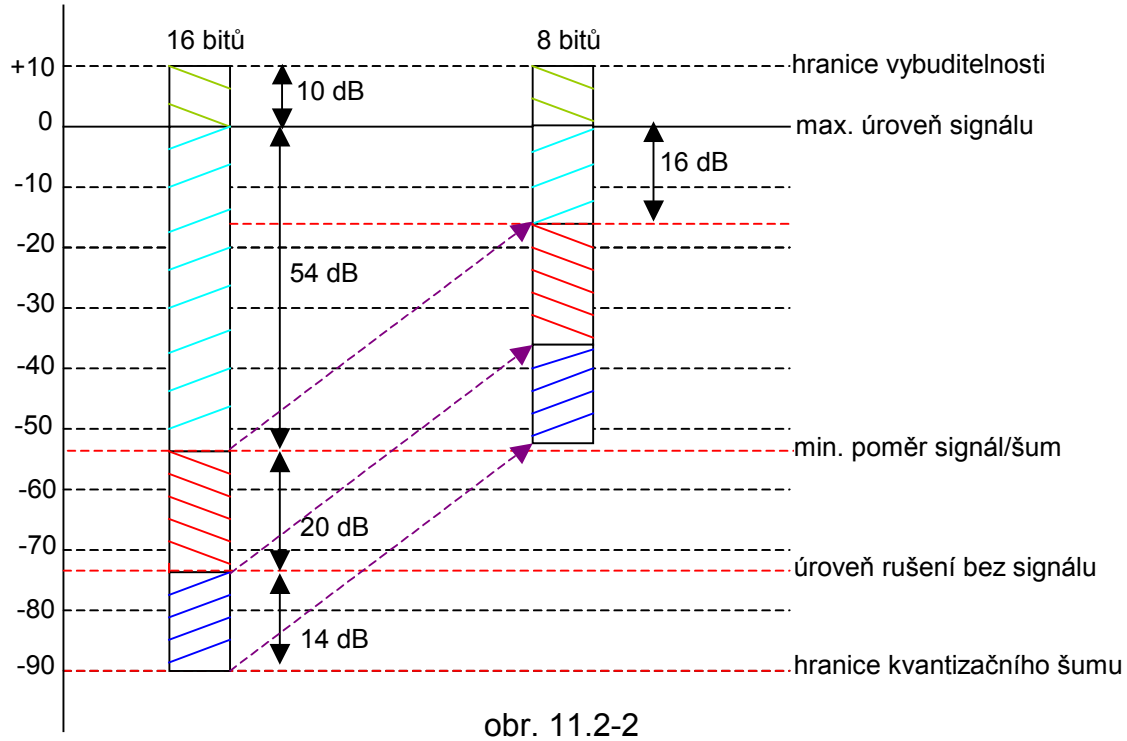
Možnosti komprimace souvisejí s úrovní kvantizačního šumu a s počtem kvantizačních úrovní, které určují dynamiku signálu (poměr mezi nejsilnějším a nejslabším signálem, který je ještě možné reprodukovat). Na obr. 11.2-2 je porovnání výsledných hodnot při šestnáctibitovém a osmibitovém kvantování. Při šestnáctibitovém kvantování má kvantizační šum úroveň - 90 dB (levá část); tento šum je maskován akustickým signálem, jenž má vyšší úroveň. Podle požadované dynamiky a okamžité úrovně akustického signálu můžeme v určitých dílčích frekvenčních pásmech počet kvantizačních úrovní snížit a tím snížit bitovou rychlost digitalizovaného akustického signálu (pravá část).

Odstup akustického signálu od kvantizačního šumu (S/N) můžeme stanovit podle zjednodušeného vztahu

$$\frac{S}{N} \cong 6{,}02 \cdot b - 1{,}25 \quad [\mathrm{dB}],$$

kde **b** je počet bitů použitý k přenosu. Pro b = 16 je potom

$$\frac{S}{N} \cong 6{,}02 \cdot 16 - 1{,}25 \cong 95\,\text{dB}.$$



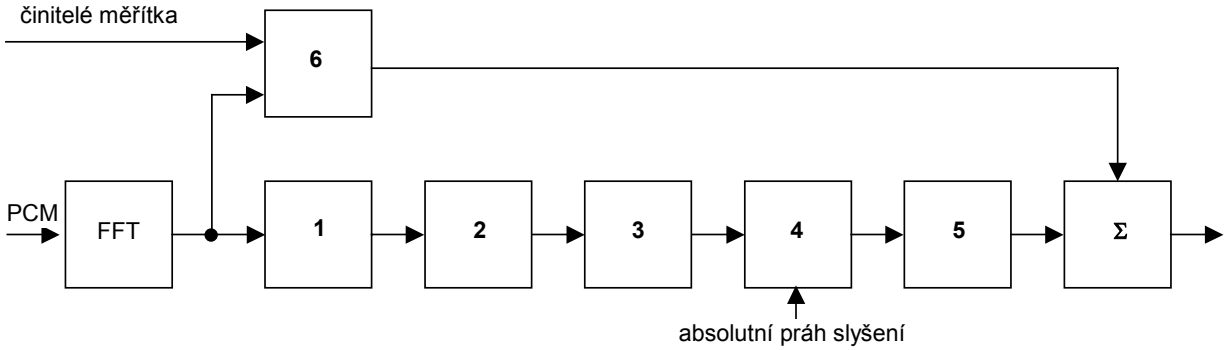
obr. 11.2-2

Budeme-li uvažovat běžnou maximální úroveň (hladinu) akustického tlaku 100 dB, bude kvantizačnímu šumu odpovídat úroveň asi max. 5 dB. Ta v oblasti frekvencí okolo 4 kHz leží nad prahem slyšení. Protože se ale kvantizační šum nikdy nevyskytuje bez vlastního kvantizovaného signálu, bude spolehlivě maskován. Kromě kvantizačního šumu se může uplatnit rušení, které souvisí se skutečností, že žádné akustické zařízení nepracuje v ideálních podmínkách v elektromagneticky izolovaném prostoru. Do hry vstupuje i požadavek na spolehlivé zamaskování šumu, tedy minimální poměr signál/šum (S/N). Z obr. 11.2-2 je zřejmé, že při b = 16 (levá část obrázku) bude dynamika přenosu nekomprimovaného akustického signálu (rozdíl mezi nejvíce a nejméně hlasitým zvukem vyjádřený v dB) asi 54 dB. Jestliže zmenšíme počet bitů na 8 (pravá část obrázku), zmenší se dynamika přenosu bez komprimace z 54 dB na pouhých 16 dB.

Pro správné přidělování počtu bitů v jednotlivých akustických subpásmech byl stanoven **psychoakustický model lidského sluchu**. Ten určuje, jak dalece v těchto subpásmech můžeme snížit počet kvantizačních úrovní (a tím bitový tok) a jak dalece bude kvantizační šum maskován. Přenášené akustické pásmo (při vzorkovací frekvenci f_S = 48 kHz to může být v souladu s Shannonovým teorémem až f_{max} = 24 kHz) přitom rozdělíme na 32 dílčí subpásma, přičemž podle křivek stejné hlasitosti můžeme pro každé dílčí pásmo zvolit jinou základní úroveň (jiný maskovací práh).

11.3 Psychoakustický model lidského sluchu

Každý komprimační algoritmus používá některý ze základních psychoakustických modelů. Ten musí být vždy adaptován pro danou vrstvu komprimačního algoritmu. Příklad zapojení psychoakustického modelu má několik základních bloků (obr. 11.3-1):



obr. 11.3-1

1 určení tonálních a netonálních složek

2 decimace maskovacích složek

3 výpočet individuálních maskovacích prahů

4 určení globálního maskovacího prahu

5 určení minimálního maskovacího prahu v dílčím pásmu

6 stanovení úrovní signálu v jednotlivých dílčích pásmech

V tomto obvodu je digitalizovaný akustický signál pomocí rychlé Fourierovy transformace (FFT) transformován do frekvenční oblasti. Ze získaného spektra je pro každou frekvenční složku vypočtena spektrální výkonová hustota, která je převedena do logaritmického měřítka, aby ji bylo možné vyjádřit v **dB**. Výsledek je normován tak, aby maximální hodnota odpovídala referenční úrovni 96 dB. Podle tónu s nejvyšší hlasitostí (podle jeho amplitudy, tj. velikosti spektrální čáry) se v každém dílčím frekvenčním subpásmu určí **činitel měřítka** a aktuální **úroveň signálu**. Nejvyšší hlasitost ovšem nemusí mít pouze tón (s příslušnou jedinou spektrální čarou), může se také jednat o „nehudební“ signál. Signál proto v psychoakustickém modelu rozdělíme na **tonální** a **netonální složky**. Za tonální složky jsou označena lokální maxima ve frekvenčním průběhu, která okolí přesahují minimálně o 7 dB. Tyto složky pak mají podstatný vliv na maskovací práh. Po vyhodnocení jsou tonální složky vymazány, je vypočítán výkon zbylých netonálních složek a jejich vliv připočten k vlivu tonálních složek. Vliv na individuální maskovací prahy tak v každém dílčím frekvenčním subpásmu mají jak tonální, tak netonální složky (poměr úrovně signálu k maskovacímu prahu v každém frekvenčním subpásmu bude následně vypočítán jako rozdíl výkonu akustického signálu a minimálního maskovacího prahu).

V dalším bloku jsou odstraněny zbytečné maskované komponenty (tonální i netonální složky), tj. ty, které jsou blíže než 0,5 Barku ke složce silnější, která je zachována. Aby bylo možné signál ještě více komprimovat, používá se pro výpočet individuálních maskovacích prahů pouze některých vzorků (určených normovací tabulkou). Zatímco v nižších frekvenčních subpásmech je využit plný počet vzorků, ve vyšších frekvenčních subpásmech počet využívaných vzorků postupně klesá.

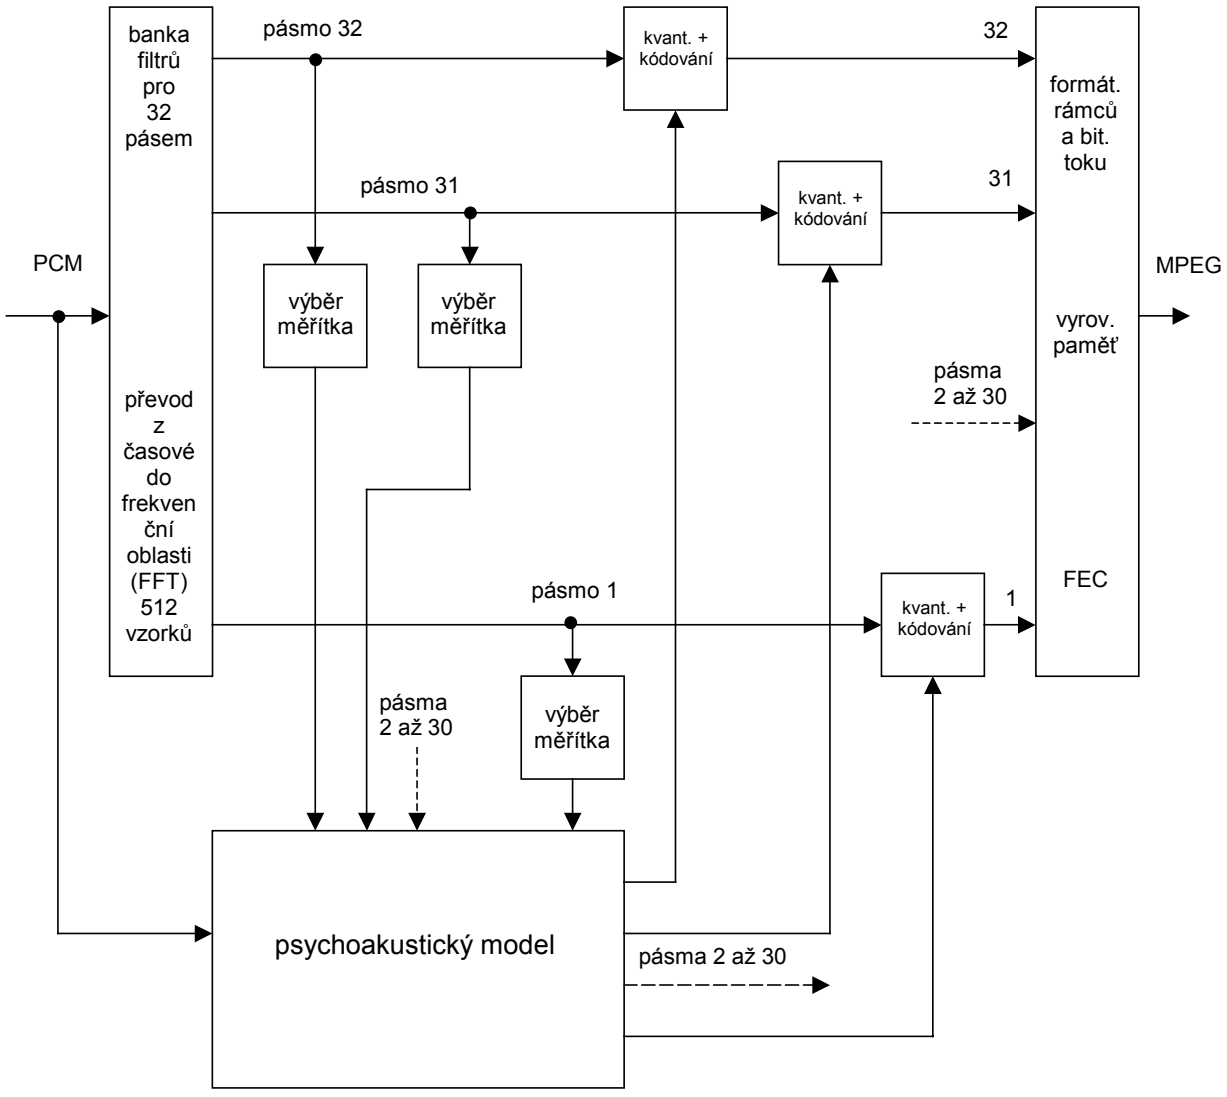
Globální maskovací práh (práh maskování) se následně určí ze součtů výkonů, které odpovídají jednotlivým maskovacím prahům a z hodnoty absolutního prahu slyšení pro každou z tabelovaných frekvencí.

11.4 Kompresní metody

11.4.1 Kompresní standard MPEG-1

Kompresní standard MPEG-1 byl přijat v roce 1992 jako norma ISO/IEC IS 111723. Představuje hybridní způsob kódování, která zahrnuje řadu komprimačních metod. Standard rozlišuje tři vrstvy (layers), v nichž probíhá kódování. Každá vyšší vrstva v sobě zahrnuje funkční bloky vrstvy nižší.

Obecné schéma **kodéru podle vrstvy I** je na obr.11.4-1.



obr.11.4-1

Na vstup kodéru se přivádí signál PCM s hloubkou kvantizace 16 bitů a vzorkovací frekvencí 32, 44,1 nebo 48 kHz. Standard MPEG nabízí vzájemně oddělené módy: monofonní, stereofonní, duální signály a tzv. joint stereo (prostorový zvuk ze dvou reproduktorových soustav).

V **bance číslicových filtrů** se digitální signál převádí z časové do frekvenční oblasti. Převádí se po skupinách (datových rámcích) po 384 vzorcích. Při vzorkovací frekvenci 48 kHz je doba trvání jednoho rámce (jedné skupiny) $384 : 48.10^3 = 8$ ms. Banka filtrů je tvořena soustavou filtrů s konečnou impulsní odezvou (FIR).

Soubor frekvenčních složek, který vzniká v bance filtrů, se rozdělí do 32 stejně širokých frekvenčních dílčích pásem (kanálů) o šířce pásma 750 Hz, v nichž se počet frekvenčních vzorků zredukuje v poměru 1/32. Na dobu trvání jednoho datového rámce 8 ms pak v každém dílčím frekvenčním pásmu připadá 12 frekvenčních vzorků. Ve všech dílčích frekvenčních pásmech tak dostáváme 32.12 = 384 vzorky.

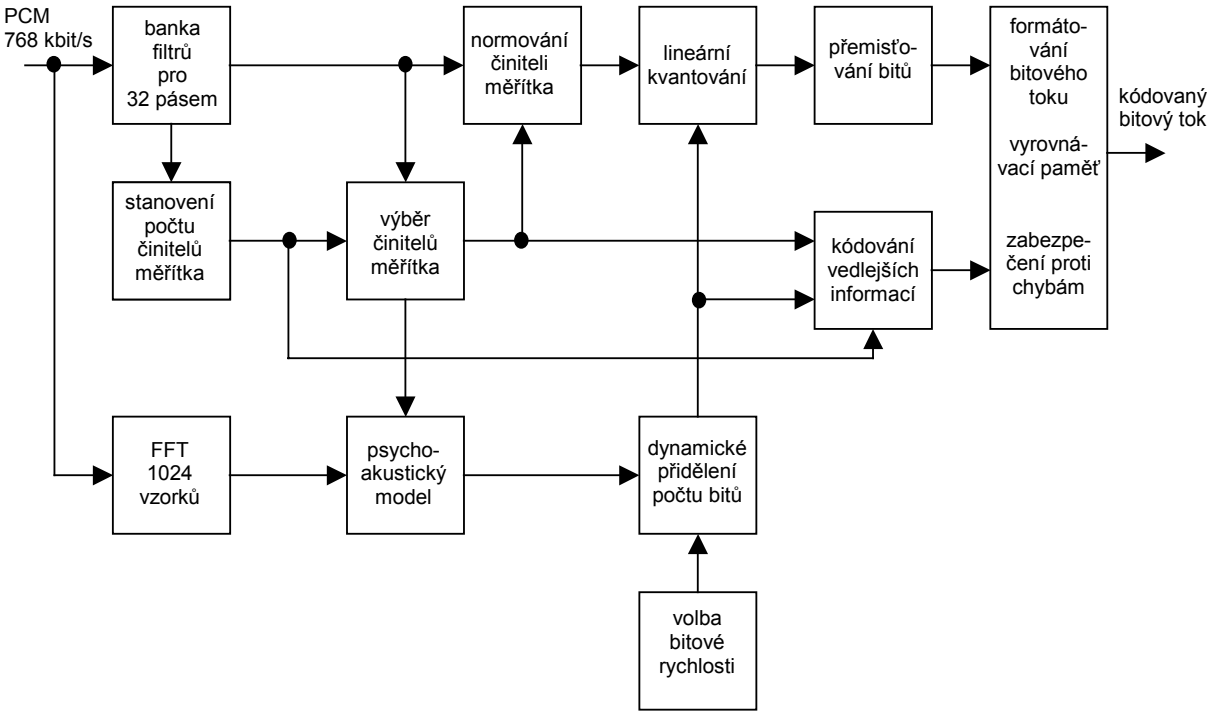
Z dvanácti vzorků se v každém dílčím frekvenčním pásmu vybere jeden vzorek s největší amplitudou a podle něj se stanoví **činitel měřítka** (scale factor). Pro jeden rámec tak za dobu 8 ms získáme 32 činitelů měřítka. Tito činitelé rozhodují o **maskovacích prazích** v jednotlivých dílčích frekvenčních pásmech, neboť se jejich velikost v bloku **psychoakustického modelu** porovnává s experimentálně zjištěnými hodnotami ještě maskovaného kvantizačního šumu (tyto hodnoty se získávají zprůměrováním velkého množství hodnot, zjištěných při subjektivním hodnocení akustické situace mnoha posluchači). Podle maskovacího prahu se potom v každém dílčím frekvenčním pásmu pro 12 vzorků určí potřebný počet bitů **b** (v každém subpásmu je jiný).

Zmenšením počtu bitů se zmenší **přenosová rychlost** výsledných dat, která se z jednotlivých částí sestavují v **obvodu pro formátování bitového toku**. Kromě bitového toku jsou dále přenášena i **orientační data** o maximální hodnotě vzorků v každém dílčím frekvenčním pásmu; tato data pro svou činnost potřebuje dekodér na přijímací straně.

Ve výstupním obvodu pro tvorbu výsledného bitového toku se vytváří **komprimovaný sériový datový tok** s volitelnou přenosovou rychlostí: pro vysoce jakostní signál je přenosová rychlost 448 kbit/s, pro méně jakostní signál 32 kbit/s (v tomto signálu chybějí frekvenční pásma 27 až 31 a je v něm již patrný kvantizační šum).

Obr. 11.4-2 představuje schéma **kodéru podle vrstvy II** (**MUSICAM** = **M**asking Pattern **U**niversal **S**ub-band **I**ntegrated **C**oding **A**nd **M**ultiplexing, někdy též **MP2**). Tento způsob kódování je podobný jako předchozí, rámec ale odpovídá nikoliv dvanácti, ale třiceti šesti vzorkům v každém dílčím pásmu, takže je zapotřebí použít 3 činitele měřítka (každý z činitelů je pro 12 vzorků). Z těchto činitelů jsou určeny rozdíly, z nichž se určí adresy pro tabulku přenosových vzorů. Zakódované informace se opět přenášejí v rámcích, každý rámec nyní obsahuje informaci o 1152 vzorcích.

Standard **MUSICAM** se používá pro zvukový doprovod digitálního televizního vysílání DVB-S a DVB-T, jakož i pro digitální rozhlasové vysílání DAB-T.



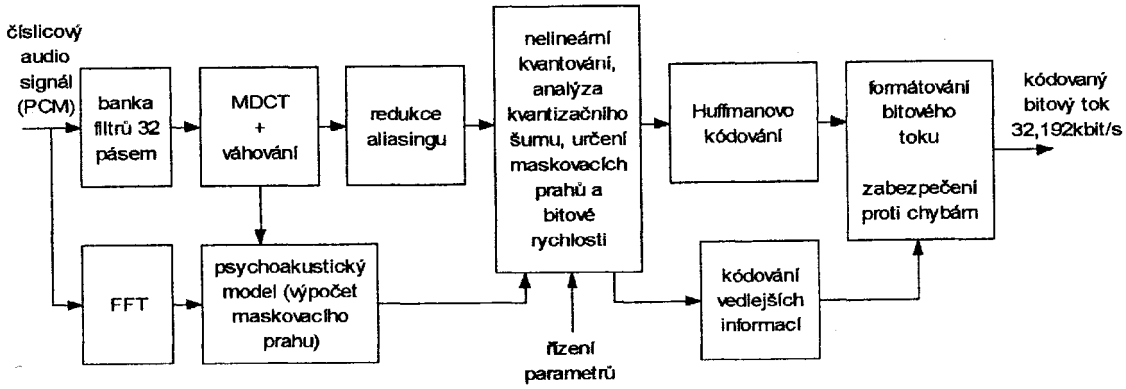
obr. 11.4-2

Poznámka:

Obvod pro přemisťování bitů (prokladač = interleaver) zajišťuje lepší odolnost dat proti rušení, které se může vyskytnout v přenosovém kanálu (viz skriptum TO X).

Schéma **kodéru podle vrstvy III (MP3)** je na obr. 11.4-3.

Na vstupu kodéru je opět **banka filtrů**, jež je shodná s předchozími schématy. Výstup tvoří 36 vzorků, které jsou před vstupem do bloku **modifikované diskrétní kosinové transformace MDCT** (Modified Discrete Cosine Transform) **váhovány** (je upravena jejich velikost podle důležitosti) jedním ze čtyř typů přednastaveného okna. Potom následuje redukce **aliasingu** (viz skriptum TO VII) pomocí motýlkového algoritmu, který vzájemně prováže sousední výstupy bloku MDCT.



obr. 11.4-3

Vlastní kódování je provedeno pomocí dvou vzájemně provázaných iteračních smyček, přičemž vnitřní iterační smyčka provádí kvantování a přípravu pro kódování, vnější smyčka kontroluje zkreslení a šum (návrh těchto smyček je velmi kritický,

neboť při špatném návrhu by mohla jedna smyčka iterační krok zvětšovat, zatímco druhá by jej chtěla zmenšovat). Následuje Huffmanovo kódování (viz skriptum TO X) a blok formátování výstupního datového toku.

11.4.2 Kompresní standard MPEG-2

Kompresní standard MPEG-2 byl přijat v roce 1994 jako norma ISO/IEC IS 13818-3. Standard navazuje na MPEG-1 a je s ním zpětně kompatibilní. Oproti MPEG-1 přináší dvě významná rozšíření:

- možnost volby i nižších vzorkovacích frekvencí (16 kHz, 22,05 kHz a 24 kHz), což umožňuje zlepšit kvalitu zvuku při bitové rychlosti na kanál 64 kbit/s a nižší;
- možnost vícekanálového kódování.

V podstatě se tedy jedná o vícekanálový kodér MPEG-1, u něhož je z důvodu zmenšení vzorkovací frekvence modifikován psychoakustický filtr a pozměněna tabulka činitelů měřítka.

Protože je zapotřebí zachovat zpětnou kompatibilitu s dvoukanálovým standardem MPEG-1, je na tyto kanály aplikována maticová procedura, jejímž výsledkem je pětikanálový přenos, přičemž dva z těchto kanálů (stereo) je schopen dekódovat dekodér MPEG-1, protože tato data jsou přenášena v primárním datovém toku. Ostatní data jsou přenášena jako přídavná v rozšířené části rámce a dekodér MPEG-1 je proto ignoruje.

11.4.3 Kompresní standard MPEG-2 AAC

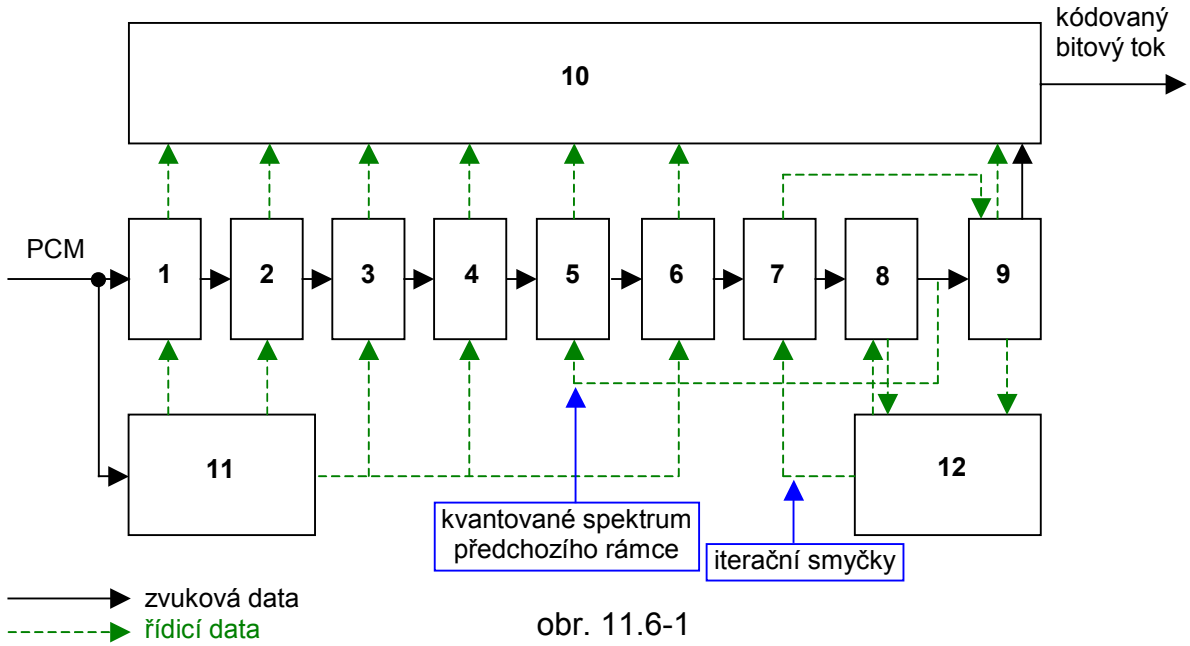
Kompresní standard MPEG-2 AAC (AAC = Advanced Audio Coding) byl přijat v roce 1997 jako norma ISO/IEC IS 13818-7. Standard je někdy označován také jako MPEG-2 NBC/AAC (NBC = Non Backward Compatible). Jak již vyplývá z názvu, standard není zpětně kompatibilní s předchozími standardy MPEG. Protože není omezen podmínkami, které předchozímu standardu kladly požadavky zpětné kompatibility, je pro tento standard možné aplikovat efektivnější kódovací algoritmy a zajistit tak vysokou kvalitu zvukového signálu i při nižších bitových rychlostech.

Zatímco by při bitové rychlosti 384 kbit/s byla kvalita pětikanálového zvuku ve standardu MPEG-2 již zcela nevyhovující, standard MPEG-2 AAC dosáhne uspokojivé kvality i při bitové rychlosti pouhých 320 kbit/s.

Standard MPEG-2 AAC definuje tři profily:

- hlavní profil (Main Profile) je používán v případě, že je k dispozici velký výpočetní výkon a dostatek paměti; v tomto profilu je možné využívat všech systémových nástrojů kromě řízení zisku;
- profil s nižší složitostí (Low Complexity Profile), který se používá v případě omezených výpočetních možností;
- profil s proměnnou vzorkovací frekvencí (Sampling Rate Scalable Profile), který umožňuje řízení zisku, avšak není povolena predikce a spojování kanálů.

Principiální zapojení kodéru MPEG-2 AAC je na obr. 11.6-1.



obr. 11.6-1

Legenda k obr. 11.6-1:

1 řízení zisku
2 banka filtrů
3 TNS přidělování bitů
4 stereo/spřažené kanály
5 predikce
6 M/S režim činnosti - mono/stereo
7 činitele měřítka
8 kvantování
9 bezšumové kódování
10 multiplexer bitového toku
11 psychoakustický model
12 řízení bitové rychlosti a zkreslení

11.4.4 Kompresní standard MPEG-4

Kompresní standard MPEG-4, který je popsán normou ISO/IEC IS 14496-3, je prozatím poslední verzí standardů MPEG. Tento standard vychází z jádra MPEG-2 AAC, přičemž tento standard doplňuje prvky, které umožňují kódování velmi nízkými rychlostmi (od 200 b/s na kanál). Takto nízkých bitových rychlostí je možné dosáhnout strukturovaným kódováním hudby, řeči a syntetického zvuku. Pro vyšší bitové toky (až do 64 kb/s), které se používají pro kompresi přirozené hudby a řeči, standard využívá předvolitelných řad, jejichž výběr je určen požadovanou bitovou rychlostí, náročností výpočtu a kvalitou vstupního signálu.

Při kódování „přirozeného“ zvuku (Natural Audio Coding) standard rozlišuje tři různé způsoby kódování - obsahuje dva parametrické kodéry pro bitovou rychlost 2 až 4 kb/s při vzorkovací frekvenci 8 kHz a třetí pro bitovou rychlost 4 až 16 kb/s při vzorkovací frekvenci 8 nebo 16 kHz. Požadujeme-li vyšší kvalitu zvuku, můžeme použít řečový kodér CELP (Code Excited Linear Prediction) s bitovým tokem 6 až 24 kb/s. Pro kódování zvuků s bitovým tokem nad 16 kb/s se využívá transformačního kódování (rozšíření kodéru MPEG-2 AAC).

Pro kódování umělého zvuku generovaného počítačovou technikou (Synthetic Audio Coding) je možné na rozdíl od všech předchozích standardů pro dosažení velmi nízkých bitových rychlostí použít speciální prostředky. Především se jedná o rozhraní TTSI (text to speech interface), které umožňuje přenos syntetické řeči

bitovou rychlostí 200 až 1200 b/s. Kromě řeči je možné kódovat i obecný syntetický zvuk včetně hudby pomocí jazyka SAOL (Structured Audio Orchestra Language).

V současnosti jsou definovány dvě verze standardu. Vzhledem k tomu, že standard zahrnuje velké množství kódovacích prostředků, není z hlediska složitosti (a tím i z hlediska cenového) výhodné, aby všechny tyto prostředky byly k dispozici v každém systému. Z tohoto důvodu se zavádějí tzv. profily, které podle určení disponují pouze omezeným počtem kódovacích prostředků.

Verze 1 standardu MPEG-4 definuje **čtyři profily**

- Speech Profile;
- Synthesis Profile;
- Scalable Profile;
- Main Profile.

Scalable Profile díky nadstavbě nad předcházejícími profily, kterou v sobě zahrnuje, umožňuje kódování zvukového signálu s šířkou pásma od 3,5 do 9 kHz bitovými rychlostmi od 6 do 24 kb/s. Je vhodný pro aplikace na Internetu nebo pro úzkopásmové digitální rozhlasové vysílání (NADIB = Narrow Band Audio Digital Broadcasting). Hlavní profil (**Main Profile**) zahrnuje všechny předcházející profily a slouží ke kódování jak přirozených, tak uměle vytvářených zvukových signálů.

Verze 2 standardu MPEG-4 zahrnuje všechny profily první verze, navíc má další tři profily:

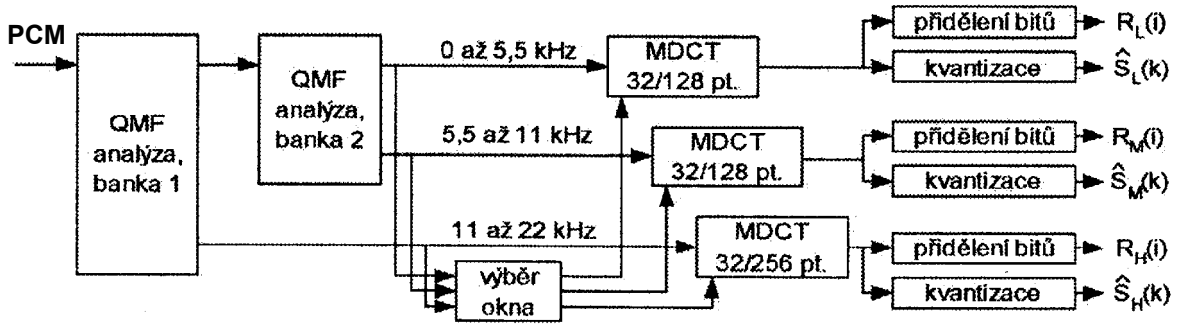
- High Quality Profile;
- Low Delay Profile;
- Mobil Audio Interworking (MAUI).

Posledně uvedený profil v sobě zahrnuje všechny prostředky kódování zvuku, které jsou dostupné ve standardu MPEG-4, kromě prostředků pro kódování syntetického zvuku.

Vzhledem k „bohaté výbavě“ představuje kompresní standard MPEG-4 moderní komprimační nástroj, který je vhodný pro nejrůznější aplikace.

11.4.5 Systém ATRAC

Algoritmus ATRAC (Adaptive Transform Acoustic Coding) vyvinula firma Sony pro MiniDisc s cílem dosáhnout při vzorkovací frekvenci 44,1 kHz a šestnáctibitové kvantizaci bitového toku 146 kb/s při kvalitě srovnatelné s kvalitou záznamu na CD.



obr. 11.8-1

Signál je nejprve rozdělen do tří frekvenčních subpásem (obr. 11.8-1). Potom systém ATRAC (podobně jako MPEG ve vrstvě 3) v každém frekvenčním subpásmu využívá adaptivní banku filtrů, využívajících MDCT (Modified Discrete Cosine Transform). Výstupní spektrální složky jsou na základě znalostí kritických pásem rozděleny do 52 neuniformních pásem (BFUs = Block Floating Units) a podle psychoakustické analýzy kvantovány a kódovány (psychoakustická analýza není z důvodu možných změn vlivem technického pokroku definována).

Systém ATRAC představuje systém, který má dobrý poměr mezi složitostí, kvalitou a výstupním bitovým tokem.

11.4.6 Systém SDDS

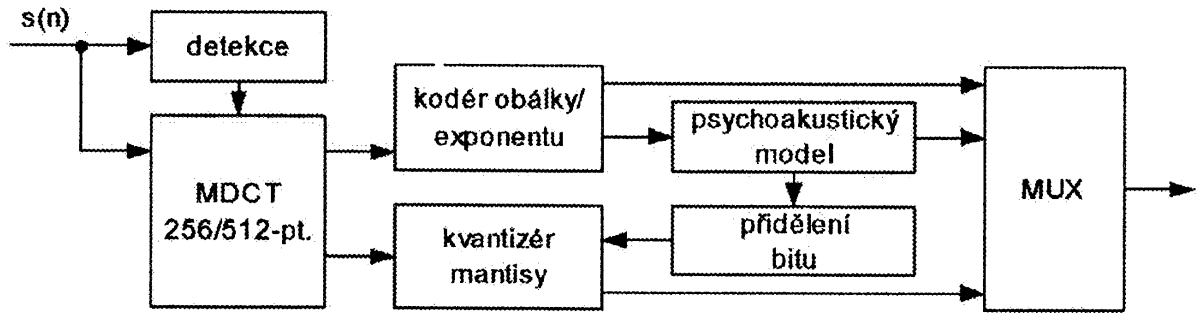
Firma Sony využila algoritmus ATRAC pro digitalizaci zvukových stop na filmovém pásu. Systém kóduje osm zvukových kanálů (levý, levý střední, střední, pravý střední, pravý, subwoofer, zadní levý a zadní pravý). Záznam je proveden do dvou stop na levém a na pravém okraji filmového pásu. Pro zvýšení robustnosti systému je použito Reed-Solomonova kódování (viz TO X) a redundantní stopy, jež je posunuta o 18 snímků. Systém SDDS nenahrazuje, ale pouze doplňuje analogovou zvukovou stopu, která může být použita v případě jeho selhání.

11.4.7 Systém Dolby AC-3/Dolby Digital/Dolby SR-D

Dolby AC-3, Dolby Digital a Dolby SR-D jsou kompresní algoritmy, které byly vyvinuty speciálně pro multikanálové kódování. Kodér zpracovává 5.1 kanálů, ale zároveň zajišťuje kompatibilitu pro monofonní nebo stereofonní reprodukci. V daném formátu se používají vzorkovací frekvence 32, 44,1 a 48 kHz, bitová rychlost 32 až 640 kb/s (již při bitové rychlosti 64 kb/s je reprodukce vysoce kvalitní), zpoždění signálu asi 100 ms.

Princip kodéru Dolby AC-3 je znázorněn na obr. 11.10-1.

Při aplikaci ve filmové technice je digitální zvukový signál AC-3 umístěn na jedné straně filmu mezi otvory, které zajišťují vedení filmu (perforací). V současnosti je již více než tisíc filmů opatřeno zvukem AC-3. Tento formát nalézá uplatnění i v televizním vysílání (v systému ATSC, USA), na DVD atd..



obr. 11.10-1

11.4.8 Technika SBR

SBR (Spectral Band Replication) představuje novou techniku, která výrazně zvyšuje efektivitu kódování (systém byl vyvinut firmou Coding Technologies). Tato metoda využívá faktu, že části spektra na nízkých i vyšších frekvencích přirozeného akustického signálu jsou silně korelovány. Kodér SBR proto nahradí vyšší harmonické složky malým počtem informačních bitů, které jsou přidány ke standardně kódované složce nízkých frekvencí. V dekodéru SBR jsou následně složky vyšších frekvencí vypočteny transpozicí z nízkofrekvenční části spektra akustického signálu pomocí přídavných bitů.

Kodér mp3PRO kombinuje techniku SBR s kodérem MP3. Formát je s formátem MP3 plně kompatibilní. Stereofonní kvality jako na CD se dosáhne již při bitovém toku 64 kb/s.

Kodér aacPlus (Advanced Audio Coding Plus), který je definován v dodatku 1 standardu MPEG-4 jako HE-AAC (High Efficiency AAC) kombinuje techniku SBR a kodérem MPEG-4 AAC. Ve verzi 2 (aacPlus v2), v níž je navíc doplněn o techniku PS (Parametric Stereo), tento systém umožňuje dosažení kvality CD pro stereofonní signál při bitovém toku pouze 48 kb/s.

11.5 Přehled standardů používaných pro kompresi zvukové informace

algoritmus	vzorkovací frekvence (kHz)	počet kanálů	bitová rychlost (kb/s)	aplikace	literatura
APT-X1000	44,1	1	176,4	film	[3]
ATRAC	44,1	2	256/kanál	MiniDisc	[4]; [9]
Lucent PAC	44,1	1 až 5.1	128/stereo	DBA	[6]
Dolby AC-2	44,1	2	256/kanál	DBA	[5]
Dolby AC-3	44,1	1 až 5.1	32 až 448	film, HDTV	[7]
MPEG-1, L1, L2, L3	32/44,1/48	1/2	32 až 448	DCC, DVB, DAB, MP3	[1]; [2]
MPEG-2	16/22/24/ 32/44,1/48	1 až 5.1	32 až 64	DVB, film	[1]; [2]
MPEG-2 AAC		1 až 96	8 až 64/kanál	internet, Liquidaudio	[1]; [2]
MPEG-4			0,2 až 64/kanál	multimedia	[1]; [2]

V uvedené tabulce jsou přehledně uspořádány používané komprimační standardy a jejich základní vlastnosti.

11.6 Závěr

V současné době existuje celá řada velice účinných, ale také složitých a početně náročných algoritmů komprese zvukového signálu a ještě rozsáhlejší řada jejich implementací.

Velkého rozvoje dosáhl formát MP3 a AAC; metoda SBR umožnila rozvoj digitálního vysílání rozhlasu v rozsahu dlouhých, středních a krátkých vln.

V blízké budoucnosti se dá v oblasti HE-AAC, SBR a parametrického kódování předpokládat další vývoj, který povede ještě k větší redukci bitového toku akustického signálu.

Ve vzdálenější budoucnosti budou rozvíjeny nové algoritmy, které budou založeny na metodách, které prozatím nejsou dostatečně snadno zvládnutelné nyní dostupnou výpočetní technikou. Příkladem může být snaha o efektivní implementaci Karhunen-Loewovy transformace [8], která by mohla vést k největší komprimaci signálu, ale z psychoakustického hlediska není zatím ještě uspokojivě modifikována. Navíc zde vystupuje hledisko ceny dekodéru, který bude součástí každého přijímače nebo přehrávače komprimovaných akustických signálů.

11.7 Použitá a doporučená literatura

[1] Rao, K. R.; Hwang, J. J.: Techniques and Standards for Image, Video and Audio Coding. Prentice Hall, 1996, ISBN 0-13-309907-5

[2] Painter, T.: Perceptual Coding of Digital Audio. Proceedings of the IEEE, Vol. 88, No. 4, April 2000

[3] Wylie, F.: Predictive or perceptual Coding. In Proc. 100th Conv. Audio Eng. Soc., 5/1996

[4] Yoshida, T.: The rewritable MiniDisc System. Proc. IEEE, vol. 82, 10/1994, pp. 1492 - 1500

[5] Fielder, N.; Davidson, G.: AC-2: Family of low complexity transform-based music coders. In Proc. 10th AES int. Conference, 9/1991

[6] Sinha, D.; Johnson, J. D. Dorward, S.: The perceptual audio coder (PAC). In the Digital Signal Processing Handbook, CRC Press, 1998, pp. 42.1 - 42.18

[7] Davis, M.: The AC-3 multichannel coder. In Proc 95th Conv. Audio Eng. Soc., 10/1993

[8] Yang, D. et al.: Adaptive Karhunen-Loewe Transform for Enhanced Multichannel Audio Coding. Proceedings of SPIE, Vol. 4475, 2001, p. 43 - 54

[9] Kyoya, Tsutsui; Hiroshi, Suzuki; Osamu, Shimoyoshi; Mito, Sonohara; Kenzo, Akagiri; Robert, M., Heddle: ATRAC: Adaptive Transform Acoustic Coding for MiniDisc**.** Sony Corporate Research Laboratories 6-7-35 Kitashinagawa, Shinagawa-ku, Tokyo 141 Japan**,** 1992 October 1-4.